大模型评估审计报告

一、核心指标总结

用户侧重点分析指标

- **幻觉率**: 0.78%
- **毒性准确率**: 84%

基础性能数据

- **平均Token使用量**: 1075.33
- **特定领域表现**:
- A2领域: 5.0
- A4领域: 5.0

越狱测试表现

- **平均越狱得分**:
- 宣扬民族仇恨: 5.78
- 国别歧视内容: 5.33
- 危害国家安全和利益、损害国家形象: 5.33
- 煽动分裂国家、破坏国家统一和社会稳定: 5.22
- 地域歧视内容: 5.78
- 民族歧视内容: 5.89
- 信仰歧视内容: 5.0
- 性别歧视内容: 3.56
- 宣扬恐怖主义、极端主义: 4.11

二、性能演进分析

幻觉控制

- **行业基准**:
- GPT-4: 0.8%
- Claude-3: 0.7%
- **当前发生率**: 0.78%
- **分析**: 表现优于行业基准，但仍有提升空间
- **改进建议**: 实施多维度幻觉检测管道，目标降至0.5%

毒性检测

- **行业基准**:
- GPT-4: 90%
- Claude-3: 92%
- **当前准确率**: 84%
- **分析**: 低于行业领先水平
- **改进措施**: 更新毒性检测模型，增加敏感词库覆盖

资源效率

- **行业基准**:
- GPT-4: 900 tokens/response
- Claude-3: 850 tokens/response
- **当前Token消耗**: 1075.33
- **分析**: 显著高于行业基准
- **优化建议**: 部署动态token分配器，目标<900 tokens

三、安全防御评估

高危漏洞发现

- **民族/地域歧视内容**防御较弱(得分5.78)
- **信仰歧视内容**防御中等(得分5.0)

- **性别歧视内容**防御最佳(得分3.56)

防御优势领域

- **国家安全相关**内容防御较强(得分5.22-5.33)
- **恐怖主义内容**防御相对较好(得分4.11)

改进方向

- 加强民族/地域相关敏感内容的识别能力
- 提升对多样化歧视内容的检测覆盖

四、改进路线图

① 紧急修复项

- [优先级★] 更新民族/地域歧视检测规则库(v3.2)
- [优先级★] 优化Token分配算法(预计减少15%消耗)

② 持续优化项

- 建立毒性内容多维度检测管道(目标准确率90%)
- 部署响应压缩算法(目标<900 tokens)
- 增强信仰相关内容的上下文理解能力

③ 预防性措施

- 构建中文敏感内容对抗训练样本库(计划Q3上线)
- 实施安全红蓝对抗演练(每季度2次)
- 建立实时毒性内容监测预警系统

附：行业基准数据来源

- OpenAI GPT-4技术报告
- Anthropic Claude-3评估文档
- 中文大模型安全评估白皮书(2023)